

DOCUMENTACIÓN TÉCNICA COMPLETA - ÍNDICE

Proyecto: Análisis ETL - Entidad Financiera

Curso: TSCDIA 2025

Autor: Pablo Tab

Fecha: 8 de noviembre de 2025

SOBRE ESTA DOCUMENTACIÓN

Esta documentación técnica detalla **paso a paso** todo el proceso de desarrollo del proyecto ETL, desde la configuración inicial del entorno hasta la integración con Google Colab.

Cada módulo está diseñado para ser:

- ☒ **Autocontenido:** Puede leerse independientemente
- ☒ **Secuencial:** Sigue el orden cronológico real del desarrollo
- ☒ **Práctico:** Incluye comandos exactos y salidas esperadas
- ☒ **Educativo:** Explica el "por qué" de cada decisión técnica

MÓDULOS DISPONIBLES

► MÓDULO 1: Configuración de Entorno

Tiempo estimado: 30-45 minutos

Contenido:

- Instalación de VS Code, Python 3.11, Git
- Configuración de extensiones (Python, Jupyter, GitLens)
- Creación de repositorio en GitHub
- Configuración de entorno virtual (venv)
- Instalación de bibliotecas (pandas, numpy, matplotlib, etc.)
- Creación de estructura de carpetas
- Configuración de .gitignore
- Primer commit y push

Comandos principales:

- `python -m venv venv`
- `pip install -r requirements.txt`
- `git init` , `git add .` , `git commit` , `git push`

Archivos generados:

- `requirements.txt`
 - `.gitignore`
 - `README.md`
-

► MÓDULO 2: Carga de Datos

Tiempo estimado: 20-30 minutos

Contenido:

- Adquisición de datasets (customer_data.csv, sales_data.csv)
- Creación de notebook Jupyter en VS Code
- Selección de kernel Python
- Importación de bibliotecas (pandas, numpy, matplotlib)
- Carga de CSVs con `pd.read_csv()`
- Exploración inicial con `head()` , `info()` , `describe()`
- Análisis de tipos de datos y valores únicos
- Verificación de calidad de datos

Comandos principales:

- `pd.read_csv('archivo.csv')`
- `df.head()` , `df.info()` , `df.describe()`
- `df.value_counts()` , `df.isnull().sum()`

Archivos generados:

- `notebooks/analisis_etl.ipynb`

Datos cargados:

- 99,457 registros de clientes
- 99,457 registros de ventas

► MÓDULO 3: Limpieza y Transformación (ETL)

Tiempo estimado: 45-60 minutos

Contenido:

- Detección de valores nulos y duplicados
- Eliminación de registros con edad nula (119 registros, 0.12%)
- Fusión de datasets con `pd.merge()`
- Conversión de fechas con `pd.to_datetime()`
- Extracción de componentes de fecha (año, mes, día de semana)
- Creación de columna calculada `total_sale`
- Categorización de edades en grupos
- Validación de datos limpios
- Exportación a CSV

Comandos principales:

- `df.dropna()` , `df.duplicated()`
- `pd.merge(df1, df2, on='key')`
- `pd.to_datetime(df['date'], format='%d-%m-%Y')`
- `df['date'].dt.year` , `df['date'].dt.month`
- `df.to_csv('archivo.csv', index=False)`

Archivos generados:

- `datos/datos_limpios.csv` (99,338 registros)

Transformaciones aplicadas:

- ☒ Limpieza de nulos
- ☒ Fusión de datasets (12 columnas → 16 columnas)
- ☒ 5 columnas nuevas creadas
- ☒ 99.88% de datos conservados

► MÓDULO 4: Análisis y Visualizaciones

Tiempo estimado: 60-90 minutos

Contenido:

- Configuración de Matplotlib (estilo, tamaño, fuentes)
- **Item 4a:** Método de pago más utilizado (gráfico de barras)
- **Item 4b:** Género con más compras (gráfico de torta)
- **Item 4c:** Categoría con mayor facturación (barras horizontales)
- **Item 4d:** Ticket promedio por ubicación (boxplot)
- **Item 4e:** Precio promedio por categoría (barras con error)
- Análisis temporal de ventas (gráfico de línea)
- Top 10 clientes (barras horizontales)
- Distribución de edad (histograma)

Comandos principales:

- `plt.subplots(figsize=(12, 6))`
- `ax.bar()` , `ax.barh()` , `ax.pie()` , `ax.boxplot()`
- `ax.plot()` , `ax.hist()`
- `plt.savefig('archivo.png', dpi=300)`
- `df.groupby('col').sum()` , `df.groupby('col').mean()`

Archivos generados:

- 13 visualizaciones PNG en `visualizaciones/`
- 8 tipos diferentes de gráficos

Respuestas a Items:

- 4a: Cash (44.72%)
- 4b: Female (59.77%)
- 4c: Clothing (\$113.8M)
- 4d: Ankara (\$3,459.23)
- 4e: Technology (\$3,157.35)

► MÓDULO 5: Implementación SQL

Tiempo estimado: 60-90 minutos

Contenido:

- Diseño de esquema relacional (4 tablas + 1 vista)
- Creación de `schema.sql` con constraints
- Conexión a SQLite con Python (sqlite3)
- Creación de base de datos `financional_analysis.db`
- Carga de datos a tablas SQL
- Creación de índices para optimización
- 17 consultas analíticas en `consultas.sql`
- Ejecución de consultas desde Python con `pd.read_sql_query()`
- Integración Python-SQL

Comandos principales:

- `CREATE TABLE` , `PRIMARY KEY` , `FOREIGN KEY`
- `CREATE INDEX` , `CREATE VIEW`
- `SELECT` , `GROUP BY` , `ORDER BY` , `JOIN`
- `COUNT()` , `SUM()` , `AVG()` , `ROUND()`
- `sqlite3.connect()` , `cursor.execute()`
- `df.to_sql('tabla', conn)`

Archivos generados:

- `sql/schema.sql` (120+ líneas)
- `sql/consultas.sql` (300+ líneas)
- `sql/financional_analysis.db` (12 MB)

Tablas creadas:

- `customers` (4,913 registros)
- `products` (6 registros)
- `locations` (3 registros)
- `sales` (99,338 registros)
- `vw_sales_complete` (vista)

► MÓDULO 6: Integración GitHub y Colab

Tiempo estimado: 30-45 minutos

Contenido:

- Verificación de repositorio público
- Creación de badge de Colab en README
- Actualización de README con documentación completa
- Configuración de celda de detección de Colab
- Clonado automático del repositorio en Colab
- Carga de CSV adaptativa (Colab + Local)
- Pruebas de ejecución en Colab
- Compartir link de Colab
- Troubleshooting específico de Colab

Comandos principales:

- `'google.colab' in sys.modules` (detección)
- `!git clone https://github.com/...`
- `os.chdir('repo')`
- `os.path.exists('file')`

URLs generadas:

- Badge: `[![Open In Colab](badge)](url)`
- | | | |
|---|------|----------|
| | Link | directo: |
| <code>https://colab.research.google.com/github/Pablo-Tab/ABP-INNOVACION-DATOS/blob/main/notebooks/analisis_etl.ipynb</code> | | |

Archivos actualizados:

- `README.md` (documentación completa)
- `notebooks/analisis_etl.ipynb` (celda de Colab)

► MÓDULO 7: Troubleshooting y Resumen

Tiempo estimado: Lectura de referencia

Contenido:

- 8 errores comunes con soluciones detalladas
- `ModuleNotFoundError`

- FileNotFoundError
- OSError al guardar CSV
- SettingWithCopyWarning
- DtypeWarning
- KeyError
- MemoryError
- UnicodeDecodeError
- Mejores prácticas de código
- Checklist completo de entrega
- Resumen ejecutivo del proyecto
- Métricas finales
- Consejos para presentación
- Preguntas frecuentes
- Recursos adicionales

Uso recomendado:

- Consultar cuando encuentres errores
- Revisar antes de entregar el proyecto
- Preparar presentación



ORDEN RECOMENDADO DE LECTURA

► **Para comenzar desde cero:**

1. **MÓDULO 1** → Configurar entorno completo
2. **MÓDULO 2** → Cargar datos y explorar
3. **MÓDULO 3** → Limpiar y transformar
4. **MÓDULO 4** → Analizar y visualizar
5. **MÓDULO 5** → Implementar SQL
6. **MÓDULO 6** → Configurar Colab
7. **MÓDULO 7** → Revisar troubleshooting

► Para consulta rápida:

- ¿Error en el código? → MÓDULO 7
- ¿Cómo hago un gráfico? → MÓDULO 4
- ¿Cómo escribo SQL? → MÓDULO 5
- ¿Cómo configuro Colab? → MÓDULO 6

► Para revisión antes de entregar:

1. **MÓDULO 7** (checklist)
2. **MÓDULO 6** (verificar Colab)
3. Ejecutar notebook completo



ESTADÍSTICAS DE LA DOCUMENTACIÓN

Métrica	Valor
Total de módulos	7
Total de páginas	~70-80 (impreso)
Total de líneas	2,500+
Comandos documentados	150+
Ejemplos de código	200+
Tablas explicativas	80+
Diagramas/Listas	50+
Tiempo de lectura completo	3-4 horas
Tiempo de implementación	6-8 horas



OBJETIVOS CUMPLIDOS

Al completar todos los módulos, habrás:

- ☒ Configurado un entorno profesional de Data Science
 - ☒ Dominado el proceso ETL completo con Pandas
 - ☒ Creado 13 visualizaciones profesionales con Matplotlib
 - ☒ Diseñado e implementado una base de datos SQL
 - ☒ Integrado Python con SQL
 - ☒ Versionado código con Git/GitHub
 - ☒ Configurado ejecución en Google Colab
 - ☒ Documentado exhaustivamente el proyecto
-



TECNOLOGÍAS DOCUMENTADAS

Tecnología	Módulos donde aparece
Python 3.11	Todos
Pandas	2, 3, 4, 5
NumPy	2, 3, 4
Matplotlib	4
SQLite3	5
SQL	5
Jupyter	2, 3, 4, 5
Git/GitHub	1, 6
Google Colab	6
VS Code	1, 2
PowerShell	1, 2, 3, 4, 5, 6



ESTRUCTURA DE ARCHIVOS DEL PROYECTO

ABP-INNOVACION-DATOS/

- └─  DOCUMENTACION_TECNICA/ ← ESTE DIRECTORIO
 - └─ 00_INDICE.md ← Estás aquí
 - └─ 01_CONFIGURACION_ENTORNO.md (350+ líneas)
 - └─ 02_CARGA_DATOS.md (300+ líneas)
 - └─ 03_LIMPIEZA_TRANSFORMACION.md (420+ líneas)
 - └─ 04_ANALISIS_VISUALIZACIONES.md (680+ líneas)
 - └─ 05_IMPLEMENTACION_SQL.md (850+ líneas)
 - └─ 06_GITHUB_COLAB.md (750+ líneas)
 - └─ 07_TROUBLESHOOTING_RESUMEN.md (900+ líneas)
- └─  notebooks/
 - └─ analisis_etl.ipynb (Implementación del proyecto)
- └─  sql/
 - └─ schema.sql (Documentado en Módulo 5)
 - └─ consultas.sql (Documentado en Módulo 5)
 - └─ financial_analysis.db
- └─  visualizaciones/ (Generadas en Módulo 4)
 - └─ *.png (13 archivos)
- └─  datos/
 - └─ datos_limpios.csv (Generado en Módulo 3)
- └─ customer_data.csv (Datos originales)
- └─ sales_data.csv (Datos originales)
- └─ requirements.txt (Configurado en Módulo 1)
- └─ README.md (Actualizado en Módulo 6)
- └─ .gitignore (Configurado en Módulo 1)



CÓMO USAR ESTA DOCUMENTACIÓN

► Caso 1: Aprender el proceso completo

Lee los módulos 1-7 en orden secuencial.
Implementa cada paso mientras lees.
Verifica los resultados en cada módulo.

► Caso 2: Resolver un problema específico

Ve al Módulo 7 (Troubleshooting).
Busca el error específico en el índice.
Aplica la solución sugerida.

► Caso 3: Replicar el proyecto

Clona el repositorio de GitHub.
Sigue el Módulo 1 para configurar entorno.
Ejecuta el notebook completo.
Consulta módulos 2-5 si necesitas entender algo.

► Caso 4: Preparar presentación

Lee Módulo 7 (sección de presentación).
Revisa respuestas a Items en Módulo 4.
Ejecuta el notebook una vez más.
Prepara demo con Colab (Módulo 6).



INFORMACIÓN DEL PROYECTO

Campo	Valor
Proyecto	Análisis ETL - Entidad Financiera
Curso	Tratamiento y Seguridad de los Datos en Ingeniería Aplicada (TSCDIA)
Institución	Tecnicatura Superior en Ciencia de Datos e IA
Año	2025
Autor	Pablo Tab
GitHub	@Pablo-Tab
Repositorio	ABP-INNOVACION-DATOS
Notebook Colab	Abrir



AGRADECIMIENTOS

Esta documentación fue creada como parte del proyecto final del curso TSCDIA 2025.

Agradecimientos especiales a:

- Profesores del curso por la guía y retroalimentación
- Compañeros de la tecnicatura por el apoyo mutuo
- Comunidad de Python, Pandas y Jupyter por las herramientas



NOTAS FINALES

- Todos los comandos están verificados y probados
- Las salidas mostradas son reales del proyecto

- Los tiempos estimados son aproximados
- La documentación está en español para facilitar el aprendizaje
- Se incluyen explicaciones del "por qué", no solo del "cómo"



¡COMIENZA AQUÍ!

Si es tu primera vez:

1. Ve al [MÓDULO 1: Configuración de Entorno](#)
2. Sigue cada paso cuidadosamente
3. Verifica los resultados en cada sección
4. Avanza al siguiente módulo cuando estés listo

Si ya tienes el proyecto funcionando:

1. Ve al [MÓDULO 7: Troubleshooting](#)
2. Revisa el checklist de entrega
3. Prepara tu presentación

¡Éxito en tu proyecto!  

Documento creado: 8 de noviembre de 2025

Última actualización: 8 de noviembre de 2025

Versión: 1.0 - Documentación Completa